Prior-Guided Attention for Weakly Supervised Acoustic Event Detection and Localization in Marine Passive Acoustic Monitoring

1 Introduction

第一段：[PAM + 生态意义（引出应用场景）]

PAM重要性、时间分布的意义、Click信号的生态意义

第二段和第三段：[弱标签 + 方法问题（收回到信号处理）]

把生态问题转成弱监督问题-现有方法不足（MIL+attention，不稳定）

第四段[解决方案]干净利落

引入先验

第五段 生态意义

生态意义点到为止

主要贡献

1.把“先验”引入attention机制

2.在没有强标签的情况下，实现并评估了定位能力

3.方法可以用于时间分布分析。“我没研究生态，但我让生态研究变得可行”。

1.真实情景下大部分标注的海洋哺乳动物PAM数据，是弱标签。强标签（秒级的定位）成本高昂，针对特定项目。为简化打弱标签的流程，使用MIL。为充分利用弱标签所隐含的信息，使用attention-based的MIL，获取信号定位，为进一步的物种识别、强标签获取提供基础。 2.用能量、脉冲数量先验的方式，引导注意力机制关注真正信号位置。加快收敛速度、提升模型可解释性。 3.对中华白海豚，Whistle信号是个体识别标签，不易采集到，且多用于个体识别。pulse信号通常用于检测中华白海豚的有无。因此采用ClickTrain、buzztrain、bursttrain信息作为包级标签依据。 4.验证该方法在辅助物种调查的能力——是否能描绘出物种时间分布?结合注意力分数来描述物种活跃度。

2 Method

2.1 数据准备与划分：

为评模型在完整季节周期上的泛化能力（外推能力），我们将包含完整四季周期的音频文件（音频1至音频8）作为独立的完整测试集，不参与任何训练或验证过程。 剩余音频文件（音频9至音频35）作为训练/验证数据来源，其中音频12因不含pulse信号（主要为噪声）而被排除，剩余26个音频文件用于5折交叉验证。交叉验证的划分方式如下：

- 随机划分26个文件为5折，保存到不同文件夹。固定随机种子；
- 每折中取训练集的最后一个 .wav 文件作为该折的验证集；
- 其余文件作为训练集。

所有音频首先进行预处理：

- 降采样至 48 kHz；
- 应用 5 kHz 高通巴特沃斯滤波器（6阶）去除低频噪声；
- 以 1分钟 为单位均匀切分为非重叠的 bag（每个 bag 包含 60 个 1秒实例）。考虑到弱监督下 bag 粒度已较粗，因此采用任何重叠即正的保守策略。

标签生成依据三个标注文件（BurstPulseTrains.csv、BuzzTrains.csv、ClickTrains.csv）中的 Train_start(s)、Train_end(s) 和 Ori_file_num 列。本研究视三者为广义 pulse瞬态事件，未作细分类。对于每个 1分钟 bag：

- 若该 bag 时间范围内存在任一 BurstPulse、Buzz 或 Click train 的时间段与之重叠，则标记为正样本（bag label = 1）；
- 否则标记为负样本（bag label = 0）；
- 对于正样本 bag，同时记录其中所有 train 片段的总持续时间求和（单位：秒），用于后续生态指标计算参考。

2.2 实例级先验特征构建

每个 1分钟 bag 被均匀划分为 60 个 1秒实例（无重叠）。为增强弱监督条件下对pulse瞬态信号的定位能力，我们为每个实例提取能量先验特征：

瞬态能量强度：计算Teager-Kaiser 能量算子在该 1秒内的最大值，因为pulse是瞬态冲击（短时能量突变），最大值能最敏锐地抓住这个“峰值涌现。而总能量值会被全秒的背景噪声淹没。平均值会被稀释。

该特征分别进行per-file内 min-max 归一化后，得到每个实例的先验分数 $ s_i \in [0,1] $，用于表征该时间片段含有pulse信号的先验置信度。

2.3 模型架构与先验引导注意力机制

- 特征提取：MFCC + 时域统计特征 → Temporal Convolutional Network (TCN) [@fonollosa2025Temporal]；

- 注意力模块：在标准注意力 logit 计算中引入先验引导：$$a_i = \text{softmax}\left(f(\mathbf{x}_i) + \alpha \cdot g(s_i) \right)$$其中 $ f(\mathbf{x}_i) $ 为模型学习得到的实例判别分数，$ g(\cdot) $ 为先验分数的映射函数（$linear(s_i) → ReLU → linear$）， $ \alpha $ 为固定的超参数，用于控制先验影响强度；

- Bag 表示：对所有实例特征进行注意力加权求和，得到 bag-level 表示；

- 分类头：二分类（sigmoid 输出 bag 是否含有 pulse）。

2.4 训练设置

采用 5 折交叉验证，每折独立训练模型。损失函数为标准二元交叉熵（可结合文献[@nihal2025Weakly]中推荐的弱监督稳定技巧）。训练完成后，将 5 个模型分别应用于完整测试集（音频1–8）的 1分钟 bag，得到5组预测结果用于后续统计分析（报告均值±标准差）。

3 Result

任务1. 检测性能（Bag-level Classification）

评估指标主要包括：

- Recall（避免漏检关键生态事件）；
- False Discovery Rate (FDR = 1 − Precision）（控制误报率）；
- Accuracy（整体正确率，作为参考）。

在完整测试集（音频1–8）上报告 5 个模型的平均性能及标准差。[@fonollosa2024Comparing]

任务2. 定位性能（Instance-level Localization under Weak Supervision）

[@nihal2025Weakly] 利用注意力权重实现弱监督定位评估。流程如下：

- 对每个正样本 bag，设定固定注意力阈值 $ \theta $（需报告敏感性分析），将 $ a_i > \theta $ 的实例视为模型预测的信号位置（记为检测集合 $ D_i $）；画出FDR-Recall图来确定最好的注意力阈值，位于图右下角的值是最好的。
- 取每个预测实例的中心时间戳作为定位点；
- 地面真值（ground truth）为标注文件中所有 train 片段的中心时间戳（记为 $ G_i $）； 采用容忍窗口 $ \tau $（建议 0.5s、1s、2s 多值报告），允许一个 ground truth 被多个检测命中，使用 many-to-many 匹配方式计算FDR、Recall和F1： $$\text{Precision} = \frac{\sum_i \text{card}{t_d \in D_i \mid \exists g_k \in G_i, |t_d-g_k|\le\tau}}{\sum_i \text{card}{D_i}}$$ $$\text{Recall} = \frac{\sum_i \text{card}{g_k \in G_i \mid \exists t_d \in D_i, |t_d-g_k|\le\tau}}{\sum_i \text{card}{G_i}}$$ $$\text{FDR} = 1 - \text{Precision}$$ 容忍窗口采用训练集基于真实 train 时长分布的中位数百分位1/5，2/5，80%。这种基于真实信号时长分布的选择，既避免了因 $ \tau $ 过大导致的虚假高 Precision，也保证了即使存在轻微的时间对齐误差（例如标注边界模糊或模型实例中心偏移）仍能被合理匹配，从而使定位评估更贴近实际生态应用场景。

任务3 消融实验

由于instance level缺少监督，其可能不是真的在定位pulse，而是学到了某种统计偏好。设计以下三组对比，验证先验引导的有效性与物理合理性：

1. Baseline：标准 Attention-based MIL（无先验）；
2. $+$ Energy：引入能量先验；
3. α 敏感性分析：固定先验特征，改变 $ \alpha \in {0, 0.5, 1.0, 2.0} $，记录收敛 epoch、检测性能及定位 Precision/Recall

对比指标：bag-level Recall / FDR + instance-level Precision / Recall

任务4 Ecological application （加分项）.

[@fonollosa2024Comparing] 在完整测试集上执行以下递进分析：

- 1.叫声计数趋势比较

统计 5 个模型在每条原始音频（1–8）中检测到的正样本 bag 数量，与人工标注的 pulse train 数量数量进行比较。绘制箱型图 + 折线图，计算 Pearson 相关系数 评估趋势一致性。做显著性检验（p-value）。

- 2.声学活动指数（AAI）比较

采用概率累加方式计算传统 AAI（每个 bag 的正样本概率之和），与真实叫声趋势对比，报告 Pearson 相关系数。做显著性检验（p-value）。

- 3.Attention-weighted Activity Index（本文提出）

为每个 1分钟 bag 计算：$$\text{AWAI} = P_{\text{bag}} \times \sum_{i:\ a_i > 0.05} a_i \times \Delta t$$（其中 $ \Delta t = 1 $ 秒，仅累加高置信实例的注意力权重和，再乘以 bag 概率，得到“等效高置信pulse活动秒数”）。与真实 train 总时长比较，计算 Pearson 相关系数。α_i的取值要做敏感性分析，通过Pearson 相关系数来确定。做显著性检验（p-value）。

通过以上三种指标的层层递进对比，展示先验引导注意力机制在弱监督条件下不仅提升检测与定位性能，还能为海洋哺乳动物声学活动的时间分布、昼夜节律及季节模式分析提供更平滑、更有生态解释力的量化依据。（写论文时，加入三种指标的可比性说明。）

文件

音频来自同一设备、同一海域、不存在domain shift 文件根目录："D:\Project_Github\audio_click_mil" original_audio_dir: "data\original_audio"， original_audio中有35个.wav文件，每个文件的最后两位数是Ori_file_num(No.)(e.g., _01.wav)。读取original_audio_dir中的data\BurstPulseTrains.csv、data\BuzzTrains.csv、data\ClickTrains.csv三个csv文件中的Train_start(s)、Train_end(s)和Ori_file_num(No.)列